

ФИНАЛЬНЫЙ ПРОЕКТ · LLM ENGINEERING · NFACTORIAL



FPL Copilot

Помощник менеджера Fantasy Premier League: новости о травмах, ожидаемые очки и оптимальный состав — с объяснением, в котором ни одно число не придумано моделью.

Zhanibek Kairgeldinov

fpl-copilot.duckdns.org · github.com/ZHKAIR/nfactorial-fpl-copilot

Раз в неделю – дедлайн и 3–4 решения с ценой ошибки

Пользователь: менеджер FPL, который перед каждым дедлайном хочет за 5 минут понять, кого продать, кого поставить капитаном, стоит ли платить –4 очка за лишний трансфер и когда играть фишку.

11 млн

менеджеров в FPL сезона 2026/27 (10 976 255 по официальному API)

Травмированный игрок в старте – минус очки и минус ранг, а трансфер обратно стоит ещё –4.

Как решают сейчас

- флаги FPL, пресс-конференции, RSS и таблицы сообщества – вручную
- готовые модели ожидаемых очков – платные и непрозрачные
- тренер по ощущениям: «он же в форме»

Почему не просто ChatGPT

- не знает текущий состав, цены и статусы травм
- уверенно выдумывает цифры и сроки возвращения
- не проверяет правила FPL: бюджет, 3 игрока из клуба, схемы

LLM маршрутизирует, извлекает и объясняет. Считает код.

ЗАДАЧА	КТО РЕШАЕТ	ГДЕ В КОДЕ
понять вопрос: интент, игроки, тур, фишки, ограничения	LLM gpt-4o-mini, T = 0, structured output	agent/llm.py
кто такой «Палмер», «Габриэл»	код матчер сущностей, транслитерация	agent/resolve.py
что пишут о травме → сигнал с цитатой и датой	поиск + LLM + проверка цитат кодом	rag/extract.py
ожидаемые очки игрока на тур	код компонентная модель xPts, без LLM	core/xpts.py
состав, трансферы, план на 5 туров, хит или нет	код MILP-оптимизатор (HiGHS)	core/optimizer.py
объяснить решение человеку	LLM только числами из фактов	agent/validate.py

Ни одно число в ответе не рождается в LLM: **валидатор** сверяет каждое имя и каждое десятичное число с фактами; нарушение → регенерация, затем видимая оговорка.

Что сделать до дедлайна — и почему

8 экранов: Брифинг · Мой состав · К дедлайну · План · Игрок · Сравнение · Чат · О системе. Живая версия — fpl-copilot.duckdns.org (вход по паролю).

ПЛАН НА GW6

Slater → Yalcouyé

+3.2

очка за 3 тура · +0.7 очка в GW6

1

Трансфер: Slater → Yalcouyé

Бесплатный, в банке останется £0.0. Slater сидит на скамейке — его продажа не стоит очков, а Yalcouyé сразу выходит в старт.

2

João Pedro — остаётся на скамейке, не продаём

Под вопросом (75 %), колено. Прогноз на GW6: у Yalcouyé 4.2 очка, у João Pedro — 3.5 очка. Но продавать не стоит: здоровым он даёт 5.5 очка за тур — больше, чем у 94 % игроков позиции; травма короткая — после неё он, скорее всего, снова в старте и подорожает. Продать можно только за £7.6, а выкупить обратно — уже за £7.7.

3

Не продаём: Palmer

Palmer под вопросом (75 %), мышцы, но здоровым даёт 5.7 очка за тур — больше, чем у 98 % игроков позиции; продать можно только за £9.6, а выкупить обратно — уже за £9.7. Травма короткая — после неё он, скорее всего, снова в старте и подорожает.

4

Поменять старт

На скамейку: Ajayi.

5

Схема 3-5-2 вместо 4-4-2

Капитан — Haaland, вице — Rogers.

СОСТАВ НА ТУР · 3-5-2

Вратарь

Raya

Защита

Calafiori

Guéhi

Van Hecke

Полузащита

Rogers

Ødegaard

Palmer

Yalcouyé **НОВЫЙ**

Cherki

Нападение

Haaland

Wissa

Скамейка

Dubravka

João Pedro

Ajayi **НА СКАМЕЙКУ**

Diop

К дедлайну → «План на тур» (команда 2558291): «João Pedro — не продаём»: здоровым даёт 5.5 очка за тур (больше, чем у 94 % позиции), продать можно за £7.6, выкупить — уже за £7.7. Всё посчитано кодом, без LLM.

GW6 · БРИФИНГ ПЕРЕД ДЕДЛАЙНОМ

Добрый вечер, Jasper.

До дедлайна нужно сделать трансфер, выбрать капитана и проверить 1 игрока с проблемами.

ДЕДЛАЙН GW6

14 д 20 ч

10 окт, 15:00

ГЛАВНЫЙ ХОД

Рекомендуем трансфер

O'Shea, Cherki → Calafiori, Tavernier

ПРОДАЁМ

OS

O'Shea

IPS · £4.0m

→

CA

Calafiori

ARS · £5.8m

CH

Cherki

MCI · £7.8m

ТА

Tavernier

BOU · £6.1m

+5.6

очка за 3 тура

бесплатный трансфер

+2.4 очка уже в ближайшем туре

Calafiori выходит в старте с шансом 93 %

Tavernier выходит в старте с шансом 97 %

> Почему этот трансфер

Подробнее к дедлайну

Спросить ассистента

КАПИТАН

SA

Saka

LEE (H)

14.8

или

HA

Haaland

LIV (A)

12.5

Капитан — Saka: в среднем 14.8 очка с учётом удвоения, на 2.2 больше, чем у Haaland. Вице-капитан — Haaland.

Сравнить двух игроков

СЛЕДИТЬ ДО ДЕДЛАЙНА

Palmer

под вопросом (75 %), мышцы

fpl_api · 21.09

Брифинг (менеджер 895045): главный трансфер +5.6 очка за 3 тура, шансы выйти в старте, капитан Saka против Haaland, кого проверить до дедлайна.

Сценарий живого показа

1. **Брифинг** (менеджер 895045): главный ход, капитан, кто под вопросом.
2. **К дедлайну** (команда 2558291): «План на тур» — почему не продаём травмированных Palmer и João Pedro.
3. **Чат**: «Кого поставить капитаном на GW6?» → ответ за ~15 с. Затем вопрос с платным трансфером → граф **останавливается** и ждёт «Подтвердить / Отклонить».
4. **Мой состав** → **скриншот Pick Team**: vision читает 15 карточек, код проверяет правила FPL, дальше те же расчёты.
5. **Cursor + MCP**: «Should I sell João Pedro?» — Skill вызывает инструменты `fpl-intelligence`.
6. **О системе**: граф агента, отрендеренный из скомпилированного LangGraph.

 Кого поставить капитаном на GW6?

 На GW6 капитаном стоит выбрать Saka. Он имеет 7.38 xPts и играет против Лидса (FSI 1). Вице-капитаном рекомендую Haaland, у которого 6.27 xPts и матч против Ливерпуля (FSI 3).

- **Saka** (ARS): 7.38 xPts, капитанские очки 14.76, 13.6% владения, против Лидса (FSI 1)
- **Haaland** (MCI): 6.27 xPts, капитанские очки 12.54, 73.7% владения, против Ливерпуля (FSI 3)
- **Tarkowski** (EVE): 5.29 xPts, капитанские очки 10.58, 16.1% владения, против Халл Сити (FSI 2)

Оговорки

- Состав = выборки GW5 (публичный API показывает трансферы текущей игровой недели только после её дедлайна).

Данные на 25.09.2026.

Чат на живом сайте: ответ за ~15 с, те же 14.76 и 12.54, что на Брифинге.


Что показать глазами

НITL-прерывание, цитаты новостей `[fpl_api, 24.09]`, одинаковые числа в UI, чате и MCP.


Резерв, если сеть упала

CLI агента, транскрипт `docs/agent_demo_output.md`, скриншоты, запись демо.

Один набор инструментов на три интерфейса



LangGraph: ветвления, циклы и два HITL



сгенерирован кодом:
`get_graph().draw_mermaid()`

Почему LangGraph

Агенту нужны ровно три вещи: условные рёбра, ограниченный цикл и `interrupt_before` с чекпоинтером – прервать граф в UI и продолжить в другом процессе. Это API графа состояний. CrewAI – ролевые «команды агентов» ради видимости, здесь один агент. Parlant – про правила диалога, не про вычисления. Свой автомат – без чекпоинтов и resume.

Ветвления

router → 16 интенгов; ставки и off-topic → `refuse` без объяснителя за ~1 с

Циклы

сигнал слабый → повторный поиск ≤ 2 раз; покупка травмирована → пересчёт 1 раз

HITL

«какой Gabriel?» и «платный трансфер / Wildcard?»;
состояние в SQLite

What if I take a -4 to bring in Saka and Guéhi?

✓ Готово за 3.0 с

Требуется подтверждения: платный трансфер (хит) — Konsa, Palmer, João Pedro → Saka, Barry, Guéhi (GW5), цена 4 очков.

Граф прерван перед узлом confirm_action; решение записывается в чекпоинт треда.


Подтвердить

Отклонить

> Как получен ответ: интент, инструменты, LLM, стоимость, валидация

Прерывание перед `confirm_action` : решение пишется в чекпоинт треда, «Отклонить» → пересчёт без хита.

«Should I sell Palmer?» – от вопроса до ответа



Два RAG: новости о травмах и правила игры

News RAG → сигнал доступности игрока

RSS BBC · Sky · Guardian · FFScout

полный текст из HTML (trafilatura)

статусы FPL

ВЫБОР	ПОЧЕМУ ТАК, А НЕ ИНАЧЕ
чанк = абзац ≤ 300 токенов + заголовок статьи	без заголовка «he trained fully on Thursday» ни о ком — не находится ни BM25, ни эмбедингом
text-embedding-3-small	корпус маленький: полная переиндексация ≈ 27 с и \$0.004
pgvector в том же Postgres	защита от утечки из будущего — одно условие <code>published_at ≤ as_of</code> в SQL
BM25 + dense → RRF → flashrank	reranker локально на CPU, без сети и денег; +4 п.п. recall@8
abstention до LLM	нет упоминаний игрока → «неизвестно» без вызова модели: 4/4, 0 ложных

Strategy KB

41 документ: официальные правила 2026/27 и гайды сообщества, 623 чанка. Ответ — только с цитатами [n] , код проверяет, что цитата дословно есть в источнике.

Без time-decay: гайд 2021 года про ЕО — лучший в корпусе, дата не сигнал.

Что получает агент

«João Pedro — под вопросом (75 %), колено» + цитаты [ffscout, 16.09] , [fpl_api, 24.09] + тур возвращения. Модель минут читает сигнал, а не текст.

Свой MCP-сервер, Skill и мультимодальность

MCP fpl-intelligence

14 tools, 5 resources, 1 prompt; stdio и streamable-http.

```
recommend_transfers,
build_gameweek_plan, predict_player,
analyze_player_risk,
search_strategy_kb ...
```

Почему MCP, а не REST: те же инструменты сразу работают в Cursor и Claude Desktop без своего клиента. Сервер отдаёт **решения**, а не сырые данные FPL. Ошибки — всегда `{error, hint}`.

Skill fpl-transfer-analyst

`SKILL.md` с триггерами: «should I sell X», «who to captain», «take a -4», «bench boost in GW N», вопросы о правилах.

Чем лучше промпта: фиксирует порядок вызовов
(`get_gameweek_context` → `diagnose_squad` → `recommend_transfers` → `analyze_player_risk`), жёсткие запреты (только числа из инструментов, никаких коэффициентов ставок) и шаблон ответа.

Vision: скриншот состава

Pick Team → строгий JSON → код резолвит имена → правила FPL (2/5/5/3, ≤ 3 из клуба) → тот же `Squad`, что из API.

Без него приложение не знает текущий состав: API отдаёт выбор только после дедлайна.

`detail=high` : 15/15, \$0.0066.
`detail=low` в 4.5× дешевле, но подменил игрока (Virgil → Livramento) — отклонён.

Golden dataset: 130 примеров, автоматические прогоны

НАБОР	N	ЧТО ПОКРЫВАЕТ
signals	27	травмы, дисквалификации, конфликт FPL и прессы, нет новостей, два Henderson, 4 Gabriel
retrieval	18	разметка по статьям, 3 запроса без ответа по построению
strategy KB	10	правила с обязательной цитатой, вопрос вне базы → NOT_COVERED
chat	60	50 RU / 10 EN, опечатки, 7 многоходовых, 5 off-topic и инъекций
chat holdout	15	написаны после последней правки промптов, прогнаны один раз

Метрики

- accuracy strict / lenient
- macro-F1
- P@8 · R@8 · MRR
- return_gw exact
- faithfulness: LLM-judge
- валидатор с 1-й попытки
- «полезен»: ручная разметка

Автоматизация

`evals.run_rag · run_kb · run_chat · run_hparams · run_models` → `evals/results/*.json` с коммитом, корпусом, ценой; бюджет `--budget-usd` .
Корпус закреплён на `as_of` — прогоны воспроизводимы.

Чего метрики не показывают

n = 27 не различает изменения меньше ~10 п.п.; faithfulness ≠ правда; смена размера судьи меняет вердикт на 47 % ответов — оценки судьи читаем как относительные.

Гипотеза → результат → решение

ЭКСПЕРИМЕНТ	ГИПОТЕЗА	РЕЗУЛЬТАТ	РЕШЕНИЕ
#1 режимы поиска	hybrid + rerank лучше dense	поиск — да (recall@8 0.837 против 0.794), точность сигнала — нет (24 против 26 из 27)	rerank в чате, dense в пакетном обновлении
#2 промпт v2 + abstention	календарь туров в промпте починит тур возвращения	0/8 → 8/8; порог rerank-score для «нет новостей» дал 4 ложных отказа	тип считает код; abstention по упоминаниям: 4/4
#3 «упало из-за корпуса»	точность 0.852 → 0.741 из-за роста корпуса	утечка из будущего: prior FPL брал снимки после as_of	prior по snapshot_at , корпус закреплён на as_of
#4 form_notes	форма отдельно от доказательств здоровья	цитаты формы 4/78 → 2/73, но точность 25 → 23/27	не выпущен, остался опцией
чат v3 → v4	чат слаб из-за структуры, а не модели	ложные отказы 10/55 → 0/55; «полезен» 17 → 49 → 54 из 60; holdout 13/15	v4 по умолчанию

gpt-4o-mini: та же точность, что у gpt-4.1, в 15 раз дешевле

МОДЕЛЬ (ИЗВЛЕЧЕНИЕ, 27 ИГРОКОВ)	ТОЧНО	ЦЕНА
gpt-4.1-nano	15/27	дешевле
gpt-4.1-mini	21/27	2.7×
gpt-4o-mini – выбрана	23/27	1×
gpt-4.1	23/27	15×
gpt-5.4-mini – кандидат на апгрейд	24/27	5.7×

Сильные модели в объяснении не вернее: gpt-4.1 вписал те же выдуманные производные числа, их ловит валидатор. Reasoning-модели – без управления temperature и с непредсказуемой ценой.

temperature = 0 везде

$T \in \{0, 0.3, 0.7\}$ на точность не влияет, но при $T = 0$ совпадают 12/23 текстов summary, при 0.7 – 0/23. Объяснитель: с 1-й попытки проходит валидатор 0.92 при $T = 0$ против 0.79 при 0.2.

max_tokens и top_p

Объяснение: 300 → обрезано 100 %, 600 → 25 %, 1000 → 0 % → взяли 1400, с русским и блоком новостей – 2000. top_p 0.5 ничего не изменил → по умолчанию.

Если OpenAI недоступна

Ответ из фактов кода без LLM, отказы и уточнения без LLM, сигналы из кэша. Переключение на другого провайдера спроектировано, но **не реализовано**.

LangSmith, публичный URL и защита от лишних трат

LangSmith

`wrap_openai` на каждом вызове OpenAI, `@traceable` в RAG и vision, callbacks графа с тегами `intent:*`, `model:*`, `strategy:*`.

скриншот дашборда LangSmith:
трейс одного сценария из демо

При отказе LangSmith (квота, 429) трейсинг в процессе выключается сам, ответы не задерживаются.

Прод: один VPS

Hetzner 2 vCPU / 4 GB (≈ €5 в месяц), docker compose: **Caddy** (HTTPS Let's Encrypt) → Streamlit → Postgres + pgvector, **ingest** новостей каждые 30 мин, бэкап базы по cron.

Guardrails

- вход по паролю, до входа — ни одного вызова OpenAI
- 200 запросов к LLM в сутки + лимит трат в OpenAI
- ставки, off-topic и инъекции → отказ (5/5, 0/55 ложных)
- новости идут в промпт как данные, инструкции внутри игнорируются

Тесты

877 тестов; граф, чат, UI и MCP — на фейках, без сети и LLM.

Что не подтвердилось и что дальше

Гипотезы, которые не подтвердились

- rerank лучше по поиску, но **не** по точности сигнала
- порог rerank-score не отличает «нет новостей» — работает правило кодом
- $T = 0 \neq$ детерминизм: воспроизводимость закрепляем кодом
- «метрика упала из-за корпуса» оказалось утечкой из будущего
- xPts v0 против официального прогноза FPL на живом GW5 — **ничья** (MAE 1.146 против 1.166), в top-20 FPL лучше
- горизонта в 3 тура мало: оптимизатор продавал травмированных звёзд «на дне» → правило «ценный актив»

Главный урок

LLM полезна там, где её ответ можно проверить кодом. Падение метрики сначала проверяем на утечку, а не объясняем «данными».

Дальше

- xPts v1 на LightGBM по истории 2016–2026
- fallback на другого провайдера LLM
- учётные записи и лимит на пользователя
- отзывы участников мини-лиги

fpl-copilot.duckdns.org

github.com/ZHKAIR/nfactorial-fpl-copilot